

机器人训练数据质量评价标准

Training Data Quality Standard for Robot Demonstrations

v1.0

文档定位： L3 质检指标体系重构的上层标准文档

适用系统： 灵机启物机器人数据质检平台

上游数据： Linker Open TeleDex processed 数据集

核心输入： telemetry.npz, videos, manifest, metadata

评价目标： 面向具身智能模型训练的数据质量评价

**L3 的目标不是评价机器人执行得有多好，而是评价这条
Demonstration 对下游策略学习有多大的训练价值。**

2026 年 6 月

目录

版本说明 5

1 背景与问题定义 6

1.1 从运动质检到训练数据质检 6

1.2 当前 L3 v1 的主要错位 6

1.3 本文档的目标 7

2 适用范围与非目标 7

2.1 适用范围 7

2.2 非目标 7

3 核心定义 8

3.1 Episode 8

3.2 Demonstration 8

3.3 Observation 8

3.4 Action 8

3.5 State 9

3.6 Training Data Quality 9

4 L3 v2 的 Mission Statement 9

5 质量哲学与设计原则 10

5.1 原则一：质量由可学习性定义，而非执行精度定义 10

5.2 原则二：评价对象是 demonstration，而不是机器人 10

5.3 原则三：评价信息价值，而不是单纯物理量 10

5.4 原则四：动作标签是训练核心，不是附属诊断量 10

5.5 原则五：任务上下文优先于统一阈值 11

5.6 原则六：单条质量与批次价值分离 11

6 高质量训练数据的标准定义 11

6.1 一句话定义 11

6.2 必要条件 11

6.3 优秀条件 12

6.4 不合格条件 12

7 质量维度体系 12

8 维度 D1：数据完整性	13
8.1 定义	13
8.2 基本要求	13
8.3 质量解释	14
9 维度 D2：时间一致性	14
9.1 定义	14
9.2 与训练的关系	14
9.3 应关注的问题	14
9.4 对现有指标的影响	14
10 维度 D3：观测可用性	15
10.1 定义	15
10.2 与 L2 的关系	15
10.3 L3 应如何使用 D3	15
11 维度 D4：动作标签质量	15
11.1 定义	15
11.2 为什么 action 质量比 tracking error 更关键	15
11.3 高质量 action 的特征	16
11.4 对现有指标的影响	16
12 维度 D5：状态动作一致性	16
12.1 定义	16
12.2 Tracking Error 的重新定位	16
12.3 推荐替代思路	17
13 维度 D6：示范过程质量	17
13.1 定义	17
13.2 高质量示范的过程特征	17
13.3 对现有 Static 指标的影响	17
14 维度 D7：任务语义一致性	18
14.1 定义	18
14.2 为什么任务语义重要	18
14.3 L3 v2 的阶段性目标	18
15 维度 D8：任务结果质量	18
15.1 定义	18
15.2 与 L3 的关系	18

15.3 失败数据的特殊处理 19

16 维度 D9：数据集价值 19

16.1 定义 19

16.2 例子 19

16.3 推荐处理方式 19

17 L3 与 L1、L2、L4 的边界 19

17.1 L1：硬性门控 19

17.2 L2：观测质量 20

17.3 L3：训练数据质量自动评估 20

17.4 L4：任务完成度 20

18 现有 L3 指标的去留建议 20

19 L3 v2 的评分与标签策略 21

19.1 不建议单一总分先行 21

19.2 三层标签 21

19.3 质量画像 21

20 Timeline 异常段的重新定义 22

20.1 从异常段到训练风险段 22

20.2 推荐风险段类型 22

20.3 Timeline 与前端交互 22

21 面向数据资产平台的字段建议 23

21.1 Episode 级输出 23

21.2 批次级输出 23

22 指标设计准入规则 23

22.1 准入问题 23

22.2 指标分级 24

23 L3 v2 推荐迭代路线 24

23.1 阶段一：重构指标语义 24

23.2 阶段二：动作标签质量增强 24

23.3 阶段三：末端空间与任务阶段 25

23.4 阶段四：任务类型与统计标定 25

23.5 阶段五：数据资产闭环 25

24 人工 QC 工作台改造建议	25
24.1 从分数展示到决策支持	25
24.2 审核员需要回答的问题	26
24.3 备注体系	26
25 训练数据准入策略	26
25.1 默认策略	26
25.2 可裁剪数据	27
25.3 拒绝数据	27
26 示例判定规则	27
26.1 场景一：Tracking Error 高但任务表现好	27
26.2 场景二：动作平滑但任务失败	27
26.3 场景三：手部动作长期 0 或 255	27
26.4 场景四：中间停顿 3 秒	28
26.5 场景五：开头 5 秒无动作	28
27 结论	28
A 附录 A：L3 v2 质量检查清单	29
B 附录 B：推荐术语替换	29
C 附录 C：后续文档拆分建议	30
D 附录 D：本文档依赖的数据语义	30

版本说明

本文档是面向 L3 阶段重构的标准文档，而不是具体算法实现文档。它的作用是先定义“什么样的机器人遥操作数据值得进入训练集”，再由该标准反推 L3 v2 的指标设计、前端展示和人工复核规则。

本文档基于以下项目事实：

- 当前平台采用 L1 至 L4 多层质检体系，其中 L3 原本定位为程序自动计算的轨迹质量评分。
- 当前 L3 已实现 LDLJ 平滑度、无效动作占比、动作饱和率、停滞占比、时间戳抖动、跟踪误差、手指颤振、执行力度和综合分 `Q_motion`。
- 上游 TeleDex 系统将 raw ROS2 MCAP 转换为 processed 数据，L3 主要使用 processed 目录下的 `telemetry.npz`。
- 在 `telemetry.npz` 中，`qpos` 表示机器人实际关节状态反馈，`actions` 表示遥操作设备发送的目标关节位置命令；机械臂通常为弧度，灵巧手通常为 0 至 255 范围值。
- 未来数据将被转换为机器人策略学习、模仿学习或 VLA 类模型可使用的训练格式，因此 L3 的核心目标应从“机器人执行质量”转向“训练数据质量”。

本文档不追求一次性确定所有阈值和公式。相反，它定义 L3 v2 的评价对象、边界、原则、质量维度和指标准入规则。后续所有 L3 指标都应能追溯到本文档中的某一条质量原则或质量维度。

1 背景与问题定义

1.1 从运动质检到训练数据质检

在机器人数据采集平台中，质量检查通常容易从机器人控制视角出发：轨迹是否平滑、关节是否跟踪目标、执行力矩是否过大、时间戳是否稳定。这些指标对机器人系统调试非常有价值，但它们不一定等价于训练数据质量。

对于下游策略学习而言，一条 episode 的价值不主要取决于机器人控制器是否完美执行每个目标关节位置，而取决于这条 demonstration 是否向模型提供了清晰、稳定、可学习的“观测到动作”的映射。模型最终学习的是在给定任务语义、视觉观测和机器人状态的条件下，应该输出什么动作。因此，L3 需要回答的问题应从：

机器人这次执行得好不好？

转变为：

这条 demonstration 是否值得作为训练样本进入数据集？

这两个问题看似接近，但会导致完全不同的指标体系。例如，actions 与 qpos 的差值能够反映控制器命令跟踪情况，却不必然反映该 demonstration 是否可用于训练；而动作抖动、无意义停顿、关键动作缺失、任务失败、观测不可用等问题，反而会直接影响模型学习。

1.2 当前 L3 v1 的主要错位

当前 L3 v1 具有工程上合理的一面：它基于 telemetry.npz 中的时序数据自动计算，能够在人工 QC 页面展示综合分、子指标和异常时间段。但从训练数据筛选的角度看，存在如下目标错位：

1. **评价对象偏向机器人执行，而非 demonstration。**例如 Tracking Error 更多评价控制器是否忠实执行目标命令，而不是数据本身是否对模型有学习价值。
2. **指标聚合偏向运动学异常，而非训练有效性。**平滑度、饱和、停滞等指标被直接合成为 Q_motion，但缺乏“是否影响模型学习”的中间解释。
3. **缺少任务语义。**同样的动作停顿、手部 0 或 255、末端轨迹绕行，在不同任务中可能含义完全不同。
4. **缺少数据集视角。**单条 episode 的指标无法回答它同类任务中的相对质量、重复性、覆盖度和多样性。
5. **缺少训练格式意识。**未来训练样本通常以 observation-state-action-task 的形式组织，而现有 L3 没有明确区分 observation 质量、action 标签质量和 state-action 一致性。

因此，L3 v2 不应只是对 L3 v1 的局部阈值调整，而应以“训练数据质量”为目标重新定义标准。

1.3 本文档的目标

本文档定义 L3 v2 的上层质量标准，具体目标包括：

- 明确 L3 v2 的评价对象是 robot demonstration，而非机器人控制器。
- 明确训练数据质量的核心标准是 learnability，即样本是否能为下游策略学习提供有效学习信号。
- 将 episode 级质量拆解为若干一级维度，为后续指标设计提供稳定框架。
- 明确哪些指标应作为核心训练质量指标，哪些只能作为辅助诊断指标。
- 明确 L3 与 L2、L4、批次报告和未来数据资产平台之间的关系。

2 适用范围与非目标

2.1 适用范围

本文档适用于以下数据与流程：

- 由 TeleDex 系统采集并转换得到的 processed episode。
- 包含多路 RGB/Depth 视频、时间戳、机器人关节状态、遥操作目标动作、力信息、同步校验、末端位姿、IMU 或触觉等字段的数据。
- 用于具身智能模型、机器人模仿学习模型、VLA 模型或行为克隆模型训练的数据筛选流程。
- L3 自动质检、人工 QC 工作台、批次报告、数据集构建和数据资产分层。

2.2 非目标

本文档明确不解决以下问题：

- 不评价机器人硬件是否健康。
- 不评价底层控制器是否达到最佳跟踪性能。
- 不替代 L4 对任务完成度的人工判断。
- 不替代 L2 对视觉质量的人工或自动判断。
- 不直接规定所有指标的最终公式和阈值。
- 不判断某个具体模型架构应该如何使用数据。

这些内容可以在后续的《L3 v2 指标设计规范》《批次级数据集质量报告规范》和《模型训练数据导出规范》中进一步展开。

3 核心定义

3.1 Episode

Episode 指一次完整的机器人遥操作采集片段。它通常对应 processed 目录下的一个 episode_XXXXXX，包含统一时间轴上的视频、机器人状态、遥操作动作、同步信息和元数据。Episode 是 L3 自动质检的基本单位。

3.2 Demonstration

Demonstration 指在特定任务提示、场景状态和机器人初始状态下，由操作者通过遥操作设备产生的一段可供模型模仿学习的行为示范。它不仅包括动作序列，还包括动作发生时的视觉观测、机器人状态、任务语义和最终任务结果。

本文档中的 demonstration 不是“机器人机械运动轨迹”的同义词。它是一个训练样本级对象，包含以下组成部分：

- 任务语义：如抓取、放置、倾倒、移动、整理等。
- 观测输入：RGB、Depth、机器人状态、可能的触觉或 IMU。
- 动作标签：遥操作设备发出的目标关节位置，通常对应 actions。
- 状态反馈：机器人实际关节位置、速度、力等，通常对应 qpos, qvel, effort。
- 结果信息：任务是否完成，是否碰撞，是否失败，是否需要人工复核。

3.3 Observation

Observation 指模型在某个时刻可见的输入信息，包括多路相机图像、深度图、机器人当前状态、任务提示以及可选传感器信息。Observation 的质量决定模型是否能从场景中理解任务状态。

3.4 Action

Action 指模型需要学习预测的动作标签。在当前 TeleDex 数据语义下，actions 来自遥操作设备发送的控制命令，通常是目标关节位置。机械臂动作以弧度表示，灵巧手动作为 0 至 255 范围值。

因此，actions 在训练数据中更接近“人类操作者意图的标签”，而不是机器人实际执行结果。

3.5 State

State 指机器人当前实际状态，主要包括 qpos, qvel, effort 和可能的末端位姿。State 可以作为训练输入的一部分，也可以用于检查动作标签和环境变化之间是否存在明显矛盾。

3.6 Training Data Quality

Training Data Quality 指一条 demonstration 对下游策略学习的有效性、清晰性、稳定性和可复用价值。它不是控制精度的同义词，也不是任务成功的单一标签，而是一个综合属性。

本文档采用如下定义：

一条高质量机器人训练数据，是指在任务语义明确、观测可用、动作标签有效、状态演化合理、任务过程完整且无严重噪声污染的条件下，能够为下游策略模型提供稳定、清晰、可学习行为信号的 demonstration。

4 L3 v2 的 Mission Statement

Mission Statement

L3 的目标不是评价机器人执行得有多好，而是评价这条 demonstration 对下游策略学习有多大的训练价值。

该 mission statement 是后续所有指标取舍的最高原则。任何拟进入 L3 v2 的指标，都必须回答至少一个问题：

- 它是否影响 observation 到 action 的学习？
- 它是否影响动作标签的可靠性？
- 它是否影响任务语义与行为之间的一致性？
- 它是否影响数据导出后的训练稳定性？
- 它是否能帮助人工快速判断该样本是否应进入训练集？

如果一个指标只能评价机器人硬件或控制器，而不能解释它如何影响训练数据质量，则该指标不应作为核心 L3 训练质量指标。它可以保留为辅助诊断信息，但不应主导总分。

5 质量哲学与设计原则

5.1 原则一：质量由可学习性定义，而非执行精度定义

Principle 1: Learnability over execution accuracy

训练数据质量的核心是模型是否能从样本中学习到清晰、稳定、可泛化的行为模式，而不是机器人是否以最小误差跟踪了每个目标关节命令。

这意味着 Tracking Error 不应天然成为核心质量指标。若一条 demonstration 的动作标签清晰、过程流畅、任务成功、观测完整，即使存在一定控制跟踪误差，它仍可能是高价值训练数据。相反，如果机器人跟踪误差很小，但操作者动作混乱、重复修正、任务失败、视频遮挡严重，这条数据也不应被认为高质量。

5.2 原则二：评价对象是 demonstration，而不是机器人

Principle 2: Demonstration-centric evaluation

L3 v2 评价的是一次示范是否适合被模型模仿，而不是机器人平台、控制器、伺服系统或硬件状态是否优秀。

这一区分对指标设计非常关键。控制器诊断类信息可以帮助定位采集现场问题，但不应与训练质量混为一谈。L3 v2 应优先关注动作标签、观测、状态演化和任务过程是否构成一条可学习 demonstration。

5.3 原则三：评价信息价值，而不是单纯物理量

Principle 3: Information value over raw physical magnitude

对训练数据而言，关键不是某个物理量大不大，而是它是否改变了样本的信息含量、标签可靠性或学习信号质量。

例如，长时间静止不一定是坏的。如果静止发生在任务开始前或完成后，它可以被裁剪；如果静止发生在等待物体稳定的任务阶段，它可能是合理的；如果静止发生在关键操作过程中并伴随动作缺失，则会降低训练价值。因此，指标必须结合时间阶段和任务语义解释。

5.4 原则四：动作标签是训练核心，不是附属诊断量

Principle 4: Action labels are first-class training signals

actions 是模型未来需要学习预测的标签，应被视为训练数据的核心组成部分，而不是仅用于与 qpos 做差的诊断变量。

这意味着 L3 v2 应重点评价 actions 是否可学习：是否连续、是否稳定、是否存在高频抖动、是否长时间无信息、是否出现非人类操作模式、是否与任务阶段相匹配。

5.5 原则五：任务上下文优先于统一阈值

Principle 5: Task-aware quality interpretation

同一数值异常在不同任务中可能有不同含义。L3 v2 应逐步从全局阈值转向任务类型感知和同类任务分布对比。

例如，灵巧手动作接近 0 或 255，在某些任务中可能代表合法的完全张开或完全闭合；在另一些任务中，快速反复接近两端则可能代表标签抖动。L3 v2 不应简单把边界值判为饱和异常，而应判断其是否构成不合理的动作模式。

5.6 原则六：单条质量与批次价值分离

Principle 6: Episode quality and dataset value are related but not identical

单条 episode 的训练质量与整个数据集的覆盖度、多样性和均衡性不同。L3 主要评价单条 demonstration，批次报告应进一步评价数据集层面的价值。

一条动作标准但非常重复的 episode 可能单条质量合格，但对扩展数据集覆盖度的边际价值较低。这类判断不适合完全放入 L3 单条总分，应进入批次级数据资产报告。

6 高质量训练数据的标准定义

6.1 一句话定义

高质量机器人训练数据应满足：任务语义明确、观测可用、动作标签有效、状态变化合理、过程连贯、关键动作充分、任务结果可信，并能够为模型提供清晰稳定的 observation-state-action 学习信号。

6.2 必要条件

一条 demonstration 至少应满足以下必要条件，才可进入训练候选集：

1. **数据结构完整。**必需文件存在，关键字段可读取，时间轴长度一致或可对齐。

- 2. **观测可用。**至少主视角视频可用，关键操作阶段无遮挡、不过曝、不严重模糊。
- 3. **动作标签存在且有效。** actions 不应为空、不应全零、不应大面积无效。
- 4. **时间顺序正确。**时间戳应单调，帧率和同步误差应在训练可接受范围内。
- 5. **任务过程可解释。**数据应包含与任务提示一致的操作过程，而不是无关动作或错误任务。
- 6. **任务结果可信。**至少应能通过 L4 或后续结果标签判断任务是否完成。

6.3 优秀条件

在满足必要条件后，一条优秀 demonstration 应进一步具备：

- 动作自然、连续、平滑，没有大量犹豫和重复修正。
- 关键动作阶段清晰，例如接近、接触、抓取、移动、释放等阶段可被视觉和状态共同解释。
- 动作标签具有足够信息密度，不是长时间无意义静止或重复无效小动作。
- 轨迹相对高效，不存在明显绕远、反复试探或无关操作。
- 同类任务中具有代表性，既不过于异常，也能补充数据集覆盖。

6.4 不合格条件

出现以下情况时，该 demonstration 应被拒绝进入训练集，或至少进入人工复核：

- 任务明显失败，且失败原因不作为专门失败数据集使用。
- 关键观察视角不可用，无法看清关键物体或机器人交互。
- 动作标签严重抖动、跳变、缺失或与任务无关。
- 时间戳错乱、同步严重异常、视频与遥测明显错位。
- 采集开始或结束裁剪错误，导致缺少关键任务阶段。
- 数据字段语义不一致，例如 actions 维度错位、手臂和手部单位混淆。

7 质量维度体系

L3 v2 应将训练数据质量拆解为九个维度。每个维度都回答一个不同的问题。

质量维度	核心问题	主要关注对象
D1 数据完整性	数据能否被稳定读取和导出？	文件、字段、维度、帧数、元数据

D2 时间一致性	时序是否可信？	timestamps、fps、同步误差、缺帧
D3 观测可用性	模型能否看清任务状态？	RGB、Depth、多视角、L2 结果
D4 动作标签质量	action 是否适合作为训练标签？	actions 连续性、抖动、有效性
D5 状态动作一致性	动作与状态变化是否相互解释？	qpos、qvel、actions、ee pose
D6 示范过程质量	操作者示范是否自然高效？	停顿、犹豫、重复修正、轨迹效率
D7 任务语义一致性	行为是否符合 task prompt？	任务类型、动作阶段、结果标签
D8 任务结果质量	任务是否完成且结果可信？	L4 pass/fail、人工备注、终态
D9 数据集价值	该样本对整体数据集是否有贡献？	同类分布、代表性、多样性、稀缺性

这九个维度并不都适合由 L3 全自动判定。其中 D1、D2、D4、D5、D6 更适合 L3 自动计算；D3 与 L2 强相关；D8 与 L4 强相关；D7 需要任务类型与人工标签逐步增强；D9 更适合批次级或数据集级报告。

8 维度 D1：数据完整性

8.1 定义

数据完整性评价 episode 是否具备进入训练流水线的基本结构条件。它回答的问题是：数据是否能被稳定读取、解析、对齐和导出。

8.2 基本要求

- processed 目录存在,且包含 telemetry.npz, manifest.json, metadata.json, camera_info.json 等核心文件。
- 至少一条可用于训练的 RGB 视频存在，且与时间戳文件长度一致。
- telemetry.npz 至少包含 timestamps, qpos, actions。
- 关键数组的第一维长度一致，或可以明确映射到统一时间轴。
- 机器人自由度维度可解释，不存在无法识别的维度错位。

8.3 质量解释

数据完整性是硬性前置条件。若数据结构无法稳定读取，则后续再好的动作或任务表现都无法进入训练流水线。D1 的结果应更多表现为 gate，而不是连续分数。

9 维度 D2：时间一致性

9.1 定义

时间一致性评价视频、状态、动作和传感器数据是否在统一时间轴上可信。它是训练数据可用性的底层保障。

9.2 与训练的关系

策略学习依赖 observation 与 action 的正确配对。如果视频帧对应的是 t 时刻，而 action 实际来自 $t + \Delta t$ ，模型将学习到错误的因果关系。同步错误的危害通常比轻微轨迹不平滑更大，因为它直接污染监督信号。

9.3 应关注的问题

- 时间戳是否单调递增。
- 帧间隔是否稳定，是否存在异常跳变。
- sync_validation_is_valid 是否大面积失败。
- sync_validation_max_diff 是否在关键动作阶段过大。
- metadata 中记录的对齐方式、裁剪范围和最大时间差是否合理。

9.4 对现有指标的影响

当前 Timestamp Jitter 和同步异常 timeline 应保留，并从“运动质量指标”改归为“时间一致性指标”。它们应具备较高优先级，因为时序错位会直接影响 observation-action 训练配对。

10 维度 D3：观测可用性

10.1 定义

观测可用性评价模型输入是否能支持任务理解。它包括视觉清晰度、视角覆盖、关键物体可见性、深度可用性和多模态一致性。

10.2 与 L2 的关系

当前体系中 L2 已经负责视觉质量人工判断，包括模糊、过曝、遮挡、深度异常等问题。因此，L3 v2 不应重复实现完整视觉质检，但应接入 L2 结果作为训练质量的一部分。

10.3 L3 应如何使用 D3

L3 v2 可在以下层面使用观测信息：

- 将 L2 视觉质量结论作为训练质量总判断的强约束。
- 在 timeline 中将关键动作阶段与视觉异常段对齐展示。
- 在未来引入“关键交互阶段可见性”指标，例如抓取瞬间手和物体是否可见。
- 对 RGB、Depth、状态曲线和动作曲线进行联合复核，而不是孤立展示运动指标。

11 维度 D4：动作标签质量

11.1 定义

动作标签质量是 L3 v2 的核心维度之一。它评价 actions 是否适合作为模型训练标签。

11.2 为什么 action 质量比 tracking error 更关键

在模仿学习或 VLA 训练中，模型通常学习从 observation 和 state 到 action 的映射。因此，actions 是监督标签。如果标签本身抖动、跳变、失真或长时间无意义，模型会直接学习到这些缺陷。

相比之下，qpos 与 actions 的差值更多反映控制器执行和机器人动态响应。它可以辅助判断状态动作一致性，但不应替代对 action 标签自身质量的评价。

11.3 高质量 action 的特征

- 连续：相邻动作之间变化合理，不出现非物理跳变。
- 稳定：不存在高频抖动或方向频繁翻转。
- 有效：在关键任务阶段包含足够动作信息，而非长期静止或全零。
- 可解释：动作变化能与视觉和状态变化对应。
- 单位一致：机械臂与灵巧手维度单位正确，归一化方式明确。

11.4 对现有指标的影响

- Dead Actions 应从“无效动作占比”重命名为“动作信息缺失”或“动作低信息段”。它不应简单惩罚所有静止，而应结合任务阶段和裁剪边界解释。
- Saturation 不应简单认为手部 0 或 255 是坏数据。更合理的判断是：是否存在长期卡边界且无状态变化，或高频在边界之间跳变。
- Chatter 应提升为核心动作标签质量指标，尤其对灵巧手训练非常重要。
- LDLJ 若继续使用，应更多关注 action 的平滑性和末端动作平滑性，而不是只评价 arm 的 qpos。

12 维度 D5：状态动作一致性

12.1 定义

状态动作一致性评价动作标签、机器人状态和场景变化之间是否存在明显矛盾。它不是要求 qpos 精确等于 actions，而是要求它们在训练意义上相互可解释。

12.2 Tracking Error 的重新定位

当前 Tracking Error 计算 $|\text{actions} - \text{qpos}|$ 的 P95，并按 arm 和 hand 加权。该指标的物理意义明确，但它更接近命令执行误差或控制器跟踪误差。

在 L3 v2 中，Tracking Error 应降级为辅助诊断指标，原因如下：

1. 它主要衡量控制器执行目标关节位置的效果，而非 action 标签是否可学习。
2. 适度的动态滞后并不必然降低 demonstration 价值。
3. 某些任务中，action 与 qpos 存在正常延迟或柔顺控制差异，直接求差可能误报。
4. 若模型训练时使用 qpos 作为当前状态、actions 作为标签，两者不完全相等并不构成监督信号错误。

12.3 推荐替代思路

L3 v2 不应简单删除 state-action 关系，而应从“精确跟踪”改为“可解释一致性”：

- 动作变化后，状态是否在合理时间内出现同向响应。
- 关键动作阶段，末端位姿是否产生与动作相符的变化。
- 是否存在 action 剧烈变化但 state 完全不响应的长段。
- 是否存在 state 大幅变化但 action 无明显变化的异常段。

这类指标比单点 $|actions - qpos|$ 更接近训练数据质量，因为它评价的是 observation-state-action 是否构成可学习因果关系。

13 维度 D6：示范过程质量

13.1 定义

示范过程质量评价操作者完成任务的过程是否自然、简洁、稳定和具有可模仿性。它是 demonstration-level 的核心维度。

13.2 高质量示范的过程特征

- 操作路径清晰，关键动作阶段明显。
- 少量必要修正可以接受，但不应有大量反复试探。
- 不应在关键阶段长时间无动作、犹豫或停顿。
- 不应存在与任务无关的绕行、误抓、碰撞或重复操作。
- 末端轨迹和手部动作应具有足够连续性。

13.3 对现有 Static 指标的影响

当前 Static 指标检测速度和动作同时低于阈值的滑动窗口。该指标有价值，但应改变解释方式：

- 发生在 episode 开头或结尾的静止，应优先作为裁剪问题处理。
- 发生在任务等待阶段的静止，不应直接惩罚。
- 发生在关键交互阶段且伴随任务无进展的静止，才应视为训练价值下降。

因此，Static 不应再简单表示“机器人不动”，而应表示“低学习信号时间段”。

14 维度 D7：任务语义一致性

14.1 定义

任务语义一致性评价 episode 中的行为是否与 task prompt 和任务类型匹配。它回答的问题是：这条数据是否在做它声称要做的事情。

14.2 为什么任务语义重要

同样的运动轨迹在不同任务下含义不同。比如手部完全闭合在抓取任务中可能是正确动作，在放置前长时间完全闭合可能也合理，但在不涉及抓取的移动任务中可能是无关动作。没有任务语义，动作质量无法被准确解释。

14.3 L3 v2 的阶段目标

在短期内，如果任务类型标签仍不完整，L3 v2 可以先支持粗粒度任务族：

- 抓取类：接近、闭合、提起、保持。
- 放置类：移动、下降、释放、撤离。
- 倾倒类：抓取、抬起、旋转、复位。
- 推拉类：接触、沿面移动、停止。
- 整理类：多阶段组合动作。

中长期应建立 task profile，使每类任务拥有自己的合理停顿、手部边界、轨迹效率和动作节奏基线。

15 维度 D8：任务结果质量

15.1 定义

任务结果质量评价任务是否成功完成，以及成功或失败标签是否可信。它与 L4 人工判断强相关。

15.2 与 L3 的关系

L3 自动指标不应取代 L4。任务完成度通常需要视觉理解和语义判断，尤其是在复杂操作中，单纯依赖轨迹很难判定是否成功。

但 L3 应与 L4 建立明确关系：

- L3 可提示可疑失败，例如长时间无动作、末端未接近目标、关键阶段缺失。
- L4 结果应作为训练数据最终准入的重要标签。
- L3 v2 的训练质量总判断应区分“动作质量好但任务失败”和“动作质量一般但任务成功”。

15.3 失败数据的特殊处理

失败数据不一定永远无价值。它可能用于失败检测、偏好学习、对比学习或恢复策略训练。但这需要明确数据集用途。默认训练成功策略时，失败数据应被隔离，不应混入成功 demonstration 数据集。

16 维度 D9：数据集价值

16.1 定义

数据集价值评价单条 episode 对整体训练集覆盖度、多样性和均衡性的贡献。它不是单条质量的直接替代。

16.2 例子

一条 demonstration 可能动作流畅、任务成功、观测清晰，因此单条质量很高。但如果同一任务、同一物体、同一初始位置已经采集了大量几乎相同的样本，它的边际价值可能较低。相反，一条稍微不完美但覆盖稀有场景或罕见物体姿态的样本，可能具有较高数据资产价值。

16.3 推荐处理方式

D9 应主要在批次报告和数据资产平台中体现，而不是直接主导 L3 单条评分。L3 可以输出可供 D9 使用的特征，例如任务类型、轨迹长度、动作分布、初末状态、质量标签等。

17 L3 与 L1、L2、L4 的边界

17.1 L1：硬性门控

L1 负责上游硬性门控，例如原始采集是否满足基本条件。L3 不应重复 L1 的职责，但如果 processed 数据中出现明显结构异常，应在 D1 数据完整性中直接标记为不可

训练。

17.2 L2：观测质量

L2 负责视觉质量判断。L3 v2 应消费 L2 的结果，将视觉质量作为训练质量的重要约束，但不应把 L2 完整重做一遍。

17.3 L3：训练数据质量自动评估

L3 v2 的核心职责是自动评价 demonstration 是否具备训练价值，尤其是动作标签、时序一致性、状态动作一致性、过程自然性和低学习信号段。

17.4 L4：任务完成度

L4 负责人工判断任务是否完成。L4 是训练数据准入的关键标签。L3 可以辅助 L4 定位异常段，但不应替代 L4 的最终语义判断。

18 现有 L3 指标的去留建议

现有指标		建议定位	原因	L3 v2 处理建议
LDLJ 平滑度		保留但改造	平滑性会影响模型学习，但仅用 arm qpos 不够	扩展到 action 平滑度和 EE 轨迹平滑度
Dead tions	Ac-	保留但重命名	长时间无动作会降低学习信号，但静止不一定坏	改为动作信息密度或低学习信号段
Saturation		降权并任务感知	手部 0/255 可能是合法动作	从边界值检测改为异常边界模式检测
Static		保留但改造	停顿可能代表犹豫或低信息段	结合阶段、裁剪和任务类型解释
Timestamp Jitter		保留且升权	时序错位直接污染训练配对	归入时间一致性核心指标
Tracking Error	Er-	降级为诊断	主要评价控制器，不直接等价于训练质量	不进入核心总分或仅低权重辅助
Chatter		保留且升权	高频抖动会污染 action 标签	作为动作标签质量核心指标

Effort	降级为诊断	力矩大不必然降低训练价值	作为硬件或碰撞辅助线索
Q_motion	废弃或重命名	Motion 目标与训练质量不完全一致	替换为 Training Quality Profile

19 L3 v2 的评分与标签策略

19.1 不建议单一总分先行

L3 v1 使用 Q_motion 将所有指标合成为一个 0 至 10 分。L3 v2 不建议一开始继续采用单一总分主导，因为不同质量维度对训练的影响不同，且部分维度具有 gate 属性。

更推荐的方式是：

- 先输出多维质量画像，再逐步建立总分。
- 区分硬失败、软风险和参考诊断。
- 总分只作为排序辅助，不作为唯一准入条件。

19.2 三层标签

建议 L3 v2 输出如下三层结果：

标签	含义	典型条件
✓ Trainable	可进入训练候选集	数据完整、时序可信、动作标签有效、无严重异常
▲ Review	需要人工复核	存在可疑低信息段、动作抖动、局部同步问题或任务语义不确定
✗ Reject	不建议进入训练集	关键文件缺失、严重同步错位、动作标签损坏、任务失败或观测不可用

19.3 质量画像

除了标签外，每条 episode 应输出质量画像，例如：

- Data Integrity: pass / review / reject
- Temporal Integrity: pass / review / reject
- Action Label Quality: pass / review / reject
- Demonstration Process Quality: pass / review / reject

- Observation Quality: linked from L2
- Task Outcome: linked from L4
- Diagnostics: tracking, effort, sync details

这种画像比单一分数更适合人工 QC，也更适合后续数据资产平台检索。

20 Timeline 异常段的重新定义

20.1 从异常段到训练风险段

当前 timeline 主要展示同步异常、跟踪误差、停滞、动作饱和、动作消失和手指颤振。L3 v2 应将其重新定义为“训练风险时间段”，即该时间段可能降低训练价值或需要人工复核。

20.2 推荐风险段类型

风险段	训练含义	UI 展示建议
同步风险段	observation 与 action 可能错位	红色，优先跳转检查
动作标签抖动段	模型可能学习到高频噪声	黄色或红色，叠加 action 曲线
低学习信号段	长时间无有效动作或无状态变化	黄色，区分开头/中间/结尾
动作跳变段	标签可能有突变或采集异常	红色，展示相关维度
状态动作矛盾段	action 与状态变化长期不一致	黄色，辅助诊断
任务阶段缺失段	关键动作可能未采到或被裁剪	需要 L4/L2 辅助判断

20.3 Timeline 与前端交互

L3 v2 的 timeline 不应只是标签列表。它应支持：

- 点击风险段跳转到视频对应时间。
- 在进度条上显示风险区间。
- 在遥操作曲线图中高亮同一时间段。
- 展示该风险段影响的质量维度，例如 D2、D4 或 D6。

- 支持人工标记“可接受”“应裁剪”“应拒绝”。

21 面向数据资产平台的字段建议

L3 v2 的输出不应只服务人工页面，还应服务未来数据资产平台。因此建议每条 episode 生成结构化质量元数据。

21.1 Episode 级输出

- training_quality_label: trainable / review / reject
- quality_profile: 九个维度的结果
- risk_segments: 训练风险时间段
- diagnostics: tracking、effort、sync 等辅助信息
- recommended_action: accept / trim / review / reject
- metric_version: L3 v2 指标版本
- task_profile_version: 任务类型标准版本

21.2 批次级输出

批次报告应进一步统计：

- 各任务类型的 trainable 比例。
- 主要拒绝原因分布。
- action label 质量分布。
- 同类任务 trajectory 分布。
- 数据多样性和重复度。
- 需要返工采集的任务类型。

这将使 L3 从单条质检工具升级为机器人数据资产治理工具。

22 指标设计准入规则

任何新指标进入 L3 v2 前，必须通过以下审查。

22.1 准入问题

1. 该指标评价的是 demonstration、action label、observation 还是 robot controller?

- 2. 该指标能否明确说明如何影响模型学习？
- 3. 该指标是否与已有指标重复？
- 4. 该指标是否需要任务类型解释？
- 5. 该指标是硬 gate、软风险还是辅助诊断？
- 6. 该指标能否定位到 timeline？
- 7. 人工审核员看到该指标后能否采取明确行动？
- 8. 该指标能否在批次级报告中产生数据资产价值？

22.2 指标分级

指标级别	含义	示例
Core Training Metric	直接影响训练数据质量	时序错位、action 抖动、动作跳变、低学习信号
Contextual Metric	需要任务语义解释	手部边界、停顿、轨迹效率、阶段完整性
Diagnostic Metric	主要用于排查系统问题	Tracking Error、Effort、IMU 冲击
Dataset Metric	主要用于批次级分析	同类一致性、多样性、重复度

23 L3 v2 推荐迭代路线

23.1 阶段一：重构指标语义

目标是先不大规模改算法，而是改命名、分类和展示逻辑。

- 将 Q_motion 替换为 Training Quality Profile。
- 将 Tracking Error 降级为 Diagnostics。
- 将 Dead、Static、Chatter、Jitter 重新归类到训练质量维度。
- UI 从“指标卡片排序”改为“质量维度画像”。

23.2 阶段二：动作标签质量增强

重点围绕 actions 设计更贴合训练的指标。

- Action smoothness。
- Action jump rate。

- Action low-information ratio。
- Hand chatter robustness。
- 边界动作模式，而非边界值本身。

23.3 阶段三：末端空间与任务阶段

利用 TeleDex 已输出的 ee_poses_* 字段，将部分质量判断从关节空间扩展到末端空间。

- EE trajectory smoothness。
- EE path efficiency。
- EE action-state consistency。
- 抓取、移动、释放等粗阶段识别。

23.4 阶段四：任务类型与统计标定

积累足够人工通过样本后，按任务类型建立统计基线。

- 每类任务建立指标分布。
- 使用 percentile 设定初始阈值。
- 结合人工审核结果校准 reject / review / trainable。
- 支持同类 episode 对比。

23.5 阶段五：数据资产闭环

最终将 L3 v2 输出接入数据集构建、模型训练和采集反馈。

- 高质量数据自动进入训练候选池。
- 低质量数据进入返工或裁剪队列。
- 批次报告反馈采集现场问题。
- 模型训练效果反向校准 L3 指标权重。

24 人工 QC 工作台改造建议

24.1 从分数展示到决策支持

当前右侧评分环展示 Q_motion，子指标卡片按严重度排序。L3 v2 建议改为：

- 顶部显示 trainable / review / reject 建议。

- 显示九维质量画像，而不是单一 motion 分。
- 对每个维度显示“为什么影响训练”。
- Timeline 展示训练风险段，并支持跳转视频和曲线。

24.2 审核员需要回答的问题

人工 QC 页面应引导审核员回答：

1. 这条 episode 是否完成任务？
2. 关键动作阶段是否可见？
3. 动作是否自然、连续、可模仿？
4. 是否存在需要裁剪的开头或结尾？
5. 是否存在局部异常但整体可用？
6. 是否建议进入训练集、复核池、裁剪池或拒绝池？

24.3 备注体系

建议新增面向训练的原因码，例如：

- action label noise
- low-information segment
- task phase missing
- observation unavailable
- temporal misalignment
- task failed
- needs trimming
- usable with caution

25 训练数据准入策略

25.1 默认策略

默认情况下，只有满足以下条件的数据进入训练候选集：

- D1 数据完整性通过。
- D2 时间一致性无严重异常。
- D3 观测质量通过或无关键视觉缺陷。
- D4 动作标签质量无严重污染。

- D8 任务结果通过或被明确标记为可用失败数据。

25.2 可裁剪数据

以下数据不应直接拒绝，而应进入裁剪或复核：

- 开头或结尾有长时间静止，但中间任务过程完整。
- 局部动作抖动，但关键阶段质量尚可。
- 单个视角不可用，但其他视角可覆盖关键动作。
- 少量同步异常不在关键阶段。

25.3 拒绝数据

以下数据应默认拒绝：

- 关键字段缺失或维度错误。
- 视频与动作严重错位。
- 动作标签大面积损坏。
- 关键任务阶段缺失。
- 任务失败且未作为失败数据集使用。
- 观测无法支持任务理解。

26 示例判定规则

26.1 场景一：Tracking Error 高但任务表现好

如果视频显示任务顺利完成，动作标签连续自然，状态也在合理时间内响应，则 Tracking Error 高不应直接导致拒绝。该 episode 可标记为 trainable，同时在 diagnostics 中记录 controller tracking risk。

26.2 场景二：动作平滑但任务失败

如果任务失败，默认不进入成功策略训练集。即使 LDLJ 或 action smoothness 很好，也只能说明运动过程平滑，不能说明 demonstration 适合成功策略学习。

26.3 场景三：手部动作长期 0 或 255

如果该任务阶段需要手完全张开或闭合，则这是正常动作。如果在无关阶段长时间卡边界，或在 0 和 255 之间高频跳变，则应标记为动作标签风险。

26.4 场景四：中间停顿 3 秒

若停顿发生在等待物体稳定或任务自然等待阶段，可以接受。若停顿发生在关键抓取前且伴随反复微调，应标记为示范犹豫或低学习信号段。

26.5 场景五：开头 5 秒无动作

如果后续任务完整，优先建议裁剪，而不是拒绝。此类问题属于数据整理问题，不是 demonstration 本体不可用。

27 结论

本文档将 L3 的核心目标从“机器人运动质量评分”重新定义为“机器人训练数据质量评价”。这一转变带来三个关键变化：

1. **评价对象改变。** L3 v2 评价 demonstration，而不是机器人控制器。
2. **评价标准改变。** 质量由 learnability 定义，而不是由 execution accuracy 定义。
3. **指标体系改变。** Tracking Error、Effort 等执行诊断指标应降级；Action Label Quality、Temporal Integrity、Demonstration Process Quality 等训练相关维度应成为核心。

最终，L3 v2 应服务于更大的机器人数据资产平台：它不仅告诉审核员“这条数据哪里异常”，更要告诉系统“这条 demonstration 是否值得训练、是否需要裁剪、是否需要复核、是否能提升数据集价值”。

A 附录 A：L3 v2 质量检查清单

编号	检查项	级别	建议动作
A1	telemetry.npz 是否存在并可读取	Gate	缺失则拒绝
A2	timestamps, qpos, actions 是否存在	Gate	缺失则拒绝
A3	时间戳是否单调且帧间隔合理	Core	异常则复核或拒绝
A4	同步误差是否集中在关键阶段	Core	关键阶段异常则拒绝
A5	动作标签是否大面积无效	Core	大面积无效则拒绝
A6	动作是否存在高频抖动	Core	严重则复核或拒绝
A7	是否存在动作跳变	Core	检查对应视频和曲线
A8	长静止是否发生在可裁剪区间	Contextual	建议裁剪
A9	手部边界动作是否符合任务语义	Contextual	结合任务类型复核
A10	任务是否完成	L4	失败则隔离
A11	关键视角是否可见	L2	不可见则复核或拒绝
A12	Tracking Error 是否异常	Diagnostic	记录但不直接拒绝
A13	Effort 是否异常	Diagnostic	作为碰撞或硬件线索

B 附录 B：推荐术语替换

原术语	建议术语	原因
Motion Quality	Training Data Quality	更符合训练数据筛选目标
Q_motion	Training Quality Profile	避免单一运动分数误导
Tracking Error	Command Tracking Diagnostic	降级为执行诊断
Dead Actions	Low-information Action Segment	更贴近训练价值
Static Ratio	Low-learning-signal Segment	避免把合理静止误判为坏
Saturation	Boundary Action Pattern	区分合法边界和异常模式

Chatter	Action Label Chatter	明确它污染训练标签
Effort	Execution Load Diagnostic	不作为核心训练质量

C 附录 C：后续文档拆分建议

本文档之后，建议继续形成以下三份规范：

1. **L3 v2 Metric Specification**：定义每个指标的输入、计算方法、阈值、timeline 生成规则和输出 schema。
2. **Manual QC UI Specification**：定义前端如何展示 Training Quality Profile、风险段、曲线联动和人工复核动作。
3. **Dataset Asset Report Specification**：定义批次级、任务级、数据集级的数据资产质量报告。

D 附录 D：本文档依赖的数据语义

本文档假设上游数据满足以下语义：

- qpos 表示机器人实际关节位置反馈。
- qvel 表示机器人实际关节速度反馈。
- effort 表示机器人力矩或力反馈。
- actions 表示遥操作控制命令，主要为目标关节位置。
- ee_poses_qpos_* 表示由实际关节状态正运动学计算得到的末端位姿。
- ee_poses_actions_* 表示由目标动作正运动学计算得到的末端位姿。
- sync_validation_* 表示转换阶段生成的同步校验结果。
- 机械臂单位通常为 rad，灵巧手位置通常为 0 至 255 范围值。

这些语义是后续 L3 v2 指标设计的基础。如果上游数据格式变化，应同步更新本文档和指标实现。