

机器人 Demonstration 数据质量证据规范

Robot Demonstration Quality Evidence
Specification

v1.0

文档定位：RDDQF 证据层设计文档

适用系统：灵机启物机器人数据质检平台 / L3 v2

上游数据：Linker Open TeleDex processed 数据与人工 QC 结果

核心目标：将质量本体转化为可解释、可计算、可复核的证据体系

承接文档：Training Data Quality Standard v1.0；Quality Ontology v1.0

输出对象：Metric Specification、Algorithm Specification、L3 Engine v2、UI 与报告系统

本规范的核心结论是：L3 v2 不应从单个指标直接给出分数，而应先收集和组织质量证据。质量分数是证据的解释结果，不是证据本身。

2026 年 6 月

目录

执行摘要 2

1 文档定位与设计目标 2

1.1 为什么需要证据层 2

1.2 从 Metric Engine 到 Evidence Engine 3

1.3 证据层的输出 3

2 证据对象模型 3

2.1 Evidence Object 3

2.2 Evidence ID 命名规则 4

2.3 Evidence 与 Metric 的区别 5

3 证据类型与粒度 6

3.1 证据类型 6

3.2 证据粒度 6

3.3 证据极性 7

4 数据源与证据能力映射 7

4.1 TeleDex processed 数据能力 7

4.2 自动证据与人工证据 8

5 总体证据图 8

5.1 Evidence Graph 概览 8

5.2 证据优先级 10

6 Learnability 证据规范 10

6.1 设计目标 10

6.2 低信息密度证据 11

6.3 状态-动作因果证据 11

7 Task-Semantic Quality 证据规范 12

7.1 设计目标 12

7.2 阶段完整性证据 12

7.3 L4 结果作为强证据 12

8 Demonstration Behavior Quality 证据规范 13

8.1 设计目标 13

8.2 Smoothness 证据 13

8.3 Correction Burden 证据	14
9 Action Label Quality 证据规范	14
9.1 设计目标	14
9.2 Action 是训练标签，不是执行结果	15
9.3 Saturation 语义证据	15
10 State and Trajectory Quality 证据规范	15
10.1 设计目标	15
10.2 Joint 与 EE 双空间证据	16
10.3 状态可信度证据	16
11 Observation Quality 证据规范	16
11.1 设计目标	16
11.2 L2 与 L3 的边界	17
12 Data Integrity and Synchronization 证据规范	17
12.1 设计目标	17
12.2 同步异常证据	18
13 Dataset-Level Quality 证据规范	18
13.1 设计目标	18
13.2 与 Episode 证据的区别	19
14 Execution Diagnostics 证据规范	19
14.1 设计目标	19
14.2 Tracking Error 的重新定位	19
15 证据聚合原则	20
15.1 避免重复惩罚	20
15.2 证据冲突处理	20
15.3 证据可信度	20
16 Timeline Evidence 设计	21
16.1 Timeline 不只是异常段	21
16.2 Timeline 输出规范	21
17 从 L3 v1 到 Evidence Layer 的迁移	22
17.1 现有指标迁移表	22
17.2 第一阶段可落地证据	22

18 Evidence Registry 实现建议	23
18.1 Registry 数据结构	23
18.2 数据库建议	24
19 前端 UI 对证据层的要求	24
19.1 质量维度优先	24
19.2 证据解释面板	24
19.3 Timeline 联动	25
20 后续文档接口	25
20.1 Metric Mapping Specification	25
20.2 Algorithm Specification	25
20.3 Implementation Specification	25
21 结论	25
A 附录 A：推荐 Evidence Registry 总表	25
B 附录 B：证据到 UI 的默认显示策略	27
C 附录 C：术语表	27
v1.1 实现同步附录：证据层解释性增强	29

执行摘要

本文档定义机器人 Demonstration 数据质量框架 (Robot Demonstration Data Quality Framework, RDDQF) 中的**证据层**。在此前已经完成的 Training Data Quality Standard 中，系统明确了 L3 v2 的目标不是评价机器人控制器执行得是否精准，而是评价一条 demonstration 对下游策略学习是否有训练价值；在 Quality Ontology 中，系统进一步将训练数据质量拆解为 Learnability、Task-Semantic Quality、Demonstration Behavior Quality、Action Label Quality、State and Trajectory Quality、Observation Quality、Data Integrity and Synchronization、Dataset-Level Quality、Execution Diagnostics 等质量维度。

本文档回答第三个问题：这些质量维度应当由哪些**证据**支撑。证据不是最终指标，也不是公式，而是位于“质量本体”和“指标算法”之间的中间层。它描述：一个质量判断为什么成立、依赖哪些数据、能否定位到时间段、是否需要人工复核、是否可用于自动评分、是否只是辅助诊断。建立证据层的目的，是避免 L3 v1 中“指标直接等于质量”的设计问题，使后续的 Metric Specification、Algorithm Specification、L3 Engine v2 和前端 UI 都能围绕同一套可解释逻辑展开。

本文档给出证据对象模型、证据类型、证据粒度、证据可信度、证据聚合原则，并为九个一级质量维度列出推荐证据清单。它同时给出当前 L3 v1 指标向证据体系的迁移方案，明确 Tracking Error 与 Effort 应属于 Execution Diagnostics，而不应作为训练价值主评分项；Dead、Static、Saturation、Chatter 等现有指标应被重新解释为低信息、动作标签质量、手部命令质量和示范行为质量的候选证据。

1 文档定位与设计目标

1.1 为什么需要证据层

如果系统直接从质量本体进入指标公式，容易出现三个问题。

第一，质量维度和指标之间会出现一对一误绑定。例如 Smoothness 被固定等同于 LDLJ，后续即便引入 SPARC、End-Effector Jerk 或 Finger Smoothness，也很难解释为什么多个算法都服务同一个质量节点。第二，分数缺乏可解释性。前端显示一个 Q 值或一个红黄绿卡片时，审核员并不知道该结论来自哪些时间段、哪些模态、哪些动作维度。第三，难以迭代。算法版本、阈值、数据源和 UI 展示都会变化，如果没有稳定的证据层，系统会在每次迭代中重写质量逻辑。

证据层的作用，是把“质量语义”和“计算方法”解耦。质量本体定义要评价什么；证据层定义用什么现象来支持评价；指标层再定义如何计算这些现象。

核心定义

Evidence 是支持某个质量判断的可观察事实或可计算信号。它可以来自 telemetry、video、depth、metadata、manifest、L2/L4 人工结果或批次统计。Evidence 不是最终分数，而是分数背后的解释单元。

1.2 从 Metric Engine 到 Evidence Engine

L3 v1 的隐含结构是：

telemetry.npz -> metric -> score -> Q_motion

L3 v2 推荐结构应当是：

Quality Ontology -> Evidence -> Metric -> Algorithm -> Result -> Explanation

换句话说，系统不应首先问“我们可以计算哪些指标”，而应先问“为了判断这条 demonstration 是否值得训练，我们需要哪些证据”。这也是从 Motion QC 升级到 Training Data Quality Assessment 的关键转变。

1.3 证据层的输出

证据层不直接产出最终评分，而产出三类结构：

- **Evidence Registry**: 证据清单，描述每个证据的定义、数据源、作用范围和与本体节点的关系。
- **Evidence Graph**: 证据与质量维度之间的关系图，用于聚合、解释和 UI 展示。
- **Evidence Contract**: 指标算法必须满足的输入输出约束，用于后续实现。

2 证据对象模型

2.1 Evidence Object

每一个证据都应被定义为一个结构化对象，而不是散落在代码里的函数。推荐对象字段如下。

字段	类型	说明
evidence_id	字符串	全局唯一 ID，例如 LRN.IDENSITY.LOW_ACTION。
name	字符串	面向人类的证据名称，例如“低动作信息密度”。

ontology_path	列表	所属质量路径，例如 Learnability / Information Density。
question	文本	该证据回答的问题。
data_sources	列表	依赖字段，例如 actions, qpos, timestamps。
temporal_scope	枚举	frame、window、segment、episode、batch、dataset。
polarity	枚举	positive、negative、diagnostic、neutral。
role	枚举	gate、score、review、explain、diagnostic、calibration。
phase_sensitive	布尔	是否需要按任务阶段解释。
task_sensitive	布尔	是否需要按任务类型标定。
confidence_model	文本	该证据的可信度来源和限制。
timeline_support	布尔	是否可以定位到时间段。
human_review	枚举	none、optional、recommended、required。
current_readiness	枚举	ready、partial、planned、research。
candidate_metrics	列表	后续可实现的指标候选，不在本文件中规定公式。

2.2 Evidence ID 命名规则

证据 ID 建议采用四段式命名：

<DOMAIN>.<SUBDOMAIN>.<EVIDENCE_NAME>.<VERSION>

示例：

LRN.IDENSITY.LOW_ACTION_SIGNAL.v1
BEH.SMOOTHNESS.EE_JERK.v1
ACT.FINGER.CHATTER.v1
DATA.SYNC.CROSS_SENSOR_DRIFT.v1
EXEC.TRACKING.COMMAND_ERROR.v1

其中 DOMAIN 推荐使用以下前缀：

前缀	对应维度	说明
----	------	----

LRN	Learnability	可学习性证据。
TASK	Task-Semantic Quality	任务语义与完成度证据。
BEH	Demonstration Behavior Quality	示范行为质量证据。
ACT	Action Label Quality	动作标签质量证据。
STATE	State and Trajectory Quality	状态与轨迹质量证据。
OBS	Observation Quality	观测质量证据。
DATA	Data Integrity and Synchronization	文件、时间、同步、转换完整性证据。
DSET	Dataset-Level Quality	批次/数据集级证据。
EXEC	Execution Diagnostics	执行诊断证据。

2.3 Evidence 与 Metric 的区别

对象	解决的问题	例子
Quality	要评价什么	Demonstration 是否流畅自然。
Evidence	为什么可以这样判断	存在末端轨迹抖动、动作反复修正、手指颤振。
Metric	用什么数字表达证据	EE jerk、reversal rate、chatter rate。
Algorithm	数字如何计算	滑窗、差分、滤波、归一化、分位数。
Result	本条 episode 的输出	score、severity、timeline segment。
Explanation	给审核员看的解释	“3.2s-4.7s 右腕末端出现高频抖动”。

设计决策 EVD-1

后续 L3 v2 代码中，Metric 不应直接挂在前端卡片上，而应通过 Evidence Registry 绑定到 Quality Ontology。前端展示的一级结构应是质量维度，指标只是证据实现。

3 证据类型与粒度

3.1 证据类型

类型	含义	典型用途
Positive Evidence	支持高质量判断的证据	动作连续推进任务、关键交互阶段完整、状态变化清晰。
Negative Evidence	支持低质量判断的证据	长时间低信息、异常跳变、无效动作、同步错误。
Diagnostic Evidence	用于解释硬件或控制问题，但不直接决定训练价值	command tracking error、effort spike、IMU shock。
Gate Evidence	可以直接拒绝数据的硬门控证据	文件缺失、严重不同步、动作标签不可用、帧数严重不足。
Review Evidence	需要人工复核的证据	疑似抓错物体、疑似中途失败但 L4 未标记。
Calibration Evidence	用于阈值标定和分布统计的证据	同类任务的平滑度分布、动作范围分布。

3.2 证据粒度

证据必须显式声明作用粒度，否则后续聚合会混乱。

粒度	说明	示例
Frame-level	单帧或相邻帧上的证据	timestamp 异常、单帧跳变。
Window-level	固定窗口内的证据	0.5s 内低信息、速度抖动。
Segment-level	连续时间段上的证据	2s 的停顿、3s 的手部颤振。
Episode-level	整条 episode 的证据	任务阶段完整性、整体动作效率。
Batch-level	同批次多条 episode 的证据	该批次整体偏慢、某任务异常率升高。
Dataset-level	训练集级证据	任务覆盖、场景多样性、冗余度。

3.3 证据极性

同一个证据节点可以有正负两种解释。例如动作范围过低是负证据，但合理的静止等待可能不是负证据；手部 0/255 饱和在抓取或释放阶段可能是正证据，在长时间抖动中则是负证据。因此，证据极性必须结合任务阶段、动作上下文和持续时间解释。

证据解释风险

不要把“观测到的现象”直接等同于“坏质量”。例如 saturation、static、large command tracking error 都可能在某些上下文中合理存在。证据层必须保留上下文解释能力。

4 数据源与证据能力映射

4.1 TeleDex processed 数据能力

当前上游 processed 数据已经为证据层提供了多模态基础。特别是 telemetry.npz 中包含统一时间轴、关节状态、动作命令、末端位姿、IMU、同步校验字段；manifest.json 提供 fps、frame count、duration、sync error 等概要信息；metadata.json 提供对齐配置、裁剪范围、sensor offsets、转换参数；视频与深度文件提供视觉观测。证据层不应只依赖 qpos/actions，而应充分使用这些信息。

数据源	主要字段/文件	可支持的证据
Telemetry joint/action	qpos, qvel, actions, effort	动作标签质量、状态连续性、信息密度、示范平滑性、手部命令质量、执行诊断。
Telemetry EE pose	ee_poses_qpos_*, ee_poses_actions_workspace	末端轨迹平滑性、路径效率、workspace 轨迹质量、task-space tracking diagnostics。
Telemetry sync	sync_validation_time, sync_validation_time_inf	跨传感器同步证据、同步异常时间窗口。
Telemetry IMU	imu_cam_top, imu_cam_left_wrist, imu_cam_right_wrist	冲击、震动、相机运动稳定性、接触异常诊断。
Manifest	fps、duration、frame count、sync error	数据完整性、采样配置一致性、时长合理性。

Metadata	alignment、 sensor offsets、 trimmed range、 device/recording summary	转换有效性、对齐可信度、设备配置一致性。
RGB/Depth video	三路 RGB、深度伪 彩、深度 PNG	视觉可用性、遮挡、目标可见性、 任务阶段证据。
L2 人工结果	visual pass/fail、 原因码	Observation Quality 的人工证 据。
L4 人工结果	task pass/fail、原 因码	Task-Semantic Quality 的人工 证据。
Batch metadata	task、batch、 operator、采集时 间	数据集分布、任务类型阈值、同类 episode 对比。

4.2 自动证据与人工证据

证据可以来自自动计算，也可以来自人工 QC。L3 v2 不应试图用自动证据完全替代 L2/L4，而应把 L2/L4 结果作为高优先级证据纳入统一质量画像。比如 L4 fail 是 Task-Semantic Quality 的强负证据；L2 pass 是 Observation Quality 的强正证据；L3 自动检测到的异常段则用于解释和复核。

5 总体证据图

5.1 Evidence Graph 概览

推荐的证据图结构如下：

```
Robot Demonstration Training Quality
|
|-- Learnability
|   |-- Information Density Evidence
|   |-- Action Effectiveness Evidence
|   |-- State-Action Causality Evidence
|   |-- Temporal Learnability Evidence
|
|-- Task-Semantic Quality
|   |-- Prompt Alignment Evidence
```

- | |-- Goal Completeness Evidence
- | |-- Phase Integrity Evidence
- | |-- Object Interaction Evidence
- |
- |-- Demonstration Behavior Quality
- | |-- Smoothness Evidence
- | |-- Continuity Evidence
- | |-- Efficiency Evidence
- | |-- Naturalness Evidence
- | |-- Correction Burden Evidence
- |
- |-- Action Label Quality
- | |-- Validity Evidence
- | |-- Dynamic Range Evidence
- | |-- Smoothness Evidence
- | |-- Saturation Semantics Evidence
- | |-- Finger Command Evidence
- |
- |-- State and Trajectory Quality
- | |-- Joint Plausibility Evidence
- | |-- EE Trajectory Evidence
- | |-- Kinematic Continuity Evidence
- | |-- Workspace Efficiency Evidence
- |
- |-- Observation Quality
- | |-- Visual Availability Evidence
- | |-- Multi-view Evidence
- | |-- Depth Evidence
- | |-- Observation-Action Alignment Evidence
- |
- |-- Data Integrity and Synchronization
- | |-- File Completeness Evidence
- | |-- Timestamp Regularity Evidence
- | |-- Sync Evidence
- | |-- Metadata Consistency Evidence
- |
- |-- Dataset-Level Quality
- | |-- Diversity Evidence

```
| |-- Coverage Evidence
| |-- Redundancy Evidence
| |-- Distribution Balance Evidence
|
|-- Execution Diagnostics
    |-- Command Tracking Evidence
    |-- Effort Evidence
    |-- IMU Shock Evidence
    |-- Hardware Health Evidence
```

5.2 证据优先级

在训练数据质量判断中，证据优先级建议分为四级。

优先级	类型	说明
P0	Hard Gate Evidence	直接决定数据不可训练，例如动作标签缺失、严重不同步、关键文件缺失。
P1	Core Training Evidence	强烈影响训练价值，例如任务失败、动作标签异常、低信息密度、关键阶段缺失。
P2	Quality Shaping Evidence	影响训练质量但通常不单独拒绝，例如轨迹效率、自然性、轻微停顿。
P3	Diagnostic Evidence	用于解释设备或控制问题，例如 tracking error、effort、IMU shock。

6 Learnability 证据规范

6.1 设计目标

Learnability 证据回答：模型能否从该 episode 中学到有效的观测到动作映射。它是 L3 v2 的核心训练价值维度之一。Learnability 不要求机器人执行完美，但要求 episode 中存在足够的状态变化、动作变化、时序连续性和可区分的学习信号。

Evidence ID	证据问题	数据源	角色
-------------	------	-----	----

LRN.IDENSITY.LOW _SIGNAL	是否存在长时间低学习信号片段	actions, qpos, timestamps	negative, score, timeline
LRN.IDENSITY.KEY _CHANGE	episode 是否包含足够关键状态变化	qpos, EE pose, video	positive, score
LRN.ACTEFF.ACTION N_CAUSES_STATE	action 是否导致状态或场景变化	actions, qpos, EE pose, video	positive/negative
LRN.CAUSALITY.STATE ACTION_PAIR	state 与 action 是否在时间上合理配对	qpos, actions, sync	score, review
LRN.TEMPORAL.SEQU ENCE_CONTINUITY	序列是否适合时序模型学习	timestamps, frame count, qpos/actions	gate/score
LRN.LABEL.DISCRIM INABILITY	action label 是否有可区分性	actions	score

6.2 低信息密度证据

低信息密度不是简单的“静止”或“动作小”。它的核心含义是：在某个时间段内，模型几乎无法从 observation-state-action 关系中学习任务推进规律。合理等待、短暂停留、抓稳后的保持动作不应被直接视为低质量；长时间无任务进展、空转、无效重复动作才是负证据。

设计决策 LRN-E1

Dead Actions 与 Static 在证据层合并为 Low Learning Signal Evidence。后续算法可以分别利用 action change、state change、EE change、video change 等多个信号，但质量解释只能归入一个低信息密度证据，避免重复惩罚。

6.3 状态-动作因果证据

对于 VLA 或语言条件策略模型，action label 必须与当前 observation 和 robot state 存在可解释关系。如果 action 在视觉上不可见的阶段发生，或 action 与 state 之间存在明显错位，模型会学习到错误或模糊的条件映射。该证据在初期可以由同步质量、动作变化与状态变化延迟、末端运动与视频变化一致性等弱信号支撑；后期可以引入视觉目标跟踪和任务阶段识别。

7 Task-Semantic Quality 证据规范

7.1 设计目标

Task-Semantic Quality 证据回答：episode 是否与任务 prompt、目标物体、操作阶段和任务结果一致。它与 L4 人工质检关系最密切。L3 v2 的目标不是完全自动判定任务成功，而是为 L4 提供过程证据，并将 L4 结果纳入训练数据质量画像。

Evidence ID	证据问题	数据源	角色
TASK.PROMPT.ALIGNMENT	动作过程是否与 task prompt 一致	task prompt, video, actions	review, planned
TASK.GOAL.COMPLETION	目标状态是否达成	L4 result, video, task metadata	gate/score
TASK.PHASE.INTEGRITY	接近、交互、移动、释放等阶段是否完整	actions, EE pose, video	score/review
TASK.OBJECT.INTERACTION	是否与正确目标物体发生交互	video, depth, EE pose	review/research
TASK.SUCCESS.COMPATIBILITY	L4 结论是否与 L3 过程证据一致	L4, L3 evidence	review
TASK.FAILURE.LOCALIZATION	若失败，是否能定位失败阶段	L4 reason, timeline evidence	explain

7.2 阶段完整性证据

多数遥操作任务都可以拆成若干阶段，例如 approach、pre-grasp、grasp/contact、transport、place/release、retreat。即使没有显式任务阶段标签，也可以利用动作强度、末端速度、手部闭合、目标交互时间等弱信号估计阶段。阶段完整性证据的价值在于：它比单个全局分数更能解释一条数据是否值得训练。

7.3 L4 结果作为强证据

L4 人工任务完成度应被视为 Task-Semantic Quality 的强证据。对于模型训练而言，任务失败数据不一定完全无用，但应与成功 demonstration 分开治理。第一阶段建议将 L4 fail 作为训练集准入的强负证据，除非后续明确构建失败恢复、纠错或负样本训练集。

8 Demonstration Behavior Quality 证据规范

8.1 设计目标

Demonstration Behavior Quality 证据回答：这条示范是否值得模型模仿。它不是评价机器人控制器，也不是评价硬件健康，而是评价示范行为风格、节奏、效率和稳定性。该维度直接决定模型是否会学习到平滑、自然、高效的行为模式。

Evidence ID	证据问题	数据源	角色
BEH.SMOOTH.JOINT	关节空间动作是否平滑	qpos, actions	score, ready
BEH.SMOOTH.EE	末端轨迹是否平滑	ee_poses_*	score, planned
BEH.CONTINUITY.PAUSE	是否存在不合理停顿	actions, qpos, EE pose	negative, timeline
BEH.EFFICIENCY.PATH	轨迹是否过度绕行	EE pose, task phase	score, planned
BEH.STABILITY.OSCILLATION	是否存在持续震荡	qpos, actions, EE, IMU	negative, timeline
BEH.NATURALNESS.RHYTHM	示范节奏是否自然	velocity profiles, phase duration	score, research
BEH.CORRECTION.RETRY	是否存在大量纠错、回退、重试	action reversals, EE path, video	negative/review
BEH.DEXTERITY.COORDINATION	手部和末端操作是否协调	hand actions, EE pose, video	score/review

8.2 Smoothness 证据

Smoothness 不应只由一个指标定义。Joint Smoothness 适合发现关节层面的抖动；Action Smoothness 直接影响模型标签；EE Smoothness 更接近任务空间质量；Finger Smoothness 对抓取类任务非常关键。因此 Smoothness 应作为证据组，而不是单一指标。

设计决策 BEH-E1

原 LDLJ 指标保留为 Joint Smoothness 的一个候选 metric，但不再直接等于“运动质量”。后续应增加 EE Smoothness 和 Action Smoothness，并在本体层统一归入 Behavior/Smoothness 与 Action Label/Smoothness。

8.3 Correction Burden 证据

Correction Burden 是 L3 v2 的新增重点证据。大量纠错、回退和重复尝试会让模型学习到不必要的探索行为。与传统控制指标相比，它更接近训练数据价值。可观测信号包括 action reversal、EE path backtracking、gripper open-close retry、phase duration outlier 等。

9 Action Label Quality 证据规范

9.1 设计目标

Action Label Quality 证据回答：actions 是否是一组可靠、清晰、可学习的监督标签。由于 TeleDex 中 actions 来源于遥操作控制命令，它在训练中通常会成为 policy 的输出标签。因此它比 qpos-action tracking 更直接影响训练质量。

Evidence ID	证据问题	数据源	角色
ACT.VALIDITY.MISSING	action 是否缺失、NaN、维度异常	actions	gate
ACT.RANGE.LOW	action 是否长期变化过低	actions	negative/score
ACT.RANGE.OUTLIER	action 是否存在异常大跳变	actions, timestamps	gate/score/timeline
ACT.SMOOTHNESS.ARM	机械臂 action 是否平滑	arm actions	score
ACT.SMOOTHNESS.HAND	手部 action 是否平滑	hand actions	score
ACT.SATURATION.SEMANTIC	饱和是否有任务语义	hand/arm actions, phase	review/score
ACT.FINGER.CHATTER	手指命令是否高频反向	hand actions	negative/timeline
ACT.FINGER.COORDINATION	多指命令是否协调	hand actions, video	score/research
ACT.SEGMENT.CLARITY	动作片段是否有清晰起止	actions, phase	explain

9.2 Action 是训练标签，不是执行结果

在当前数据结构中，actions 代表遥操作设备发送的目标关节位置。它不是模型预测结果，也不是 qpos 的后验估计。因此，Action Label Quality 的核心问题不是“机器人是否跟上了 action”，而是“action 本身是否能作为模型要学习的标签”。这一区分决定了 Tracking Error 不应作为训练质量主指标。

9.3 Saturation 语义证据

手部 0/255 可能代表完全张开或完全闭合，是抓取任务中的合法动作状态。简单把 0/255 计为 saturation error 会产生误报。证据层应把 saturation 分为三种情况：合法阶段性饱和、长时间卡死饱和、伴随高频抖动的异常饱和。只有后两者应作为负证据。

设计决策 ACT-E1

Hand Saturation 不再作为独立硬惩罚证据。它必须和持续时间、任务阶段、动作变化、手指颤振和任务结果共同解释。

10 State and Trajectory Quality 证据规范

10.1 设计目标

State and Trajectory Quality 证据回答：机器人状态轨迹是否可信、连续、几何合理，并能支持模型学习。它与 Demonstration Behavior Quality 有交叉，但关注点不同：Behavior 更关注示范风格，State and Trajectory 更关注状态序列本身是否可靠。

Evidence ID	证据问题	数据源	角色
STATE.JOINT.PLAUSIBILITY	qpos/qvel 是否合理连续	qpos, qvel	gate/score
STATE.JOINT.JUMP	是否存在关节不可能跳变	qpos, timestamps	negative/timeline
STATE.EE.PLAUSIBILITY	EE pose 是否连续可信	ee_poses_*	score/planned
STATE.EE.PATH_QUALITY	末端路径是否适合任务学习	EE pose, task phase	score
STATE.KIN.CONTINUITY	joint 与 EE 运动是否一致	qpos, EE pose	diagnostic/review

STATE.WORKSPACE.EFFICIENCY	工作空间路径是否过度绕行	EE pose, task goal	score/planned
STATE.COVERAGE.CHANGE	episode 是否包含有效状态覆盖	qpos, EE pose, video	positive/score

10.2 Joint 与 EE 双空间证据

L3 v1 主要在 joint space 计算指标。L3 v2 应采用 joint space 与 task space 双证据。Joint space 对维度异常、机械臂抖动、手部命令有效性很敏感；EE space 更接近任务学习，适合评价路径效率、末端平滑性、接触前稳定性和操作阶段完整性。

10.3 状态可信度证据

State evidence 还应用于发现数据转换或传感器问题，例如 qpos 某些维度长期为零、qvel 与 qpos 差分不一致、EE pose 与 qpos 推导关系异常等。这类证据可能属于 Data Integrity 或 Execution Diagnostics，需要根据上下文归属。

11 Observation Quality 证据规范

11.1 设计目标

Observation Quality 证据回答：模型输入是否可用于学习。当前 L2 已经负责视觉质量人工判断，但对于训练数据质量系统而言，观测质量仍需要被纳入统一证据图。未来如果训练模型使用 RGB、Depth、state、language prompt，则任何输入模态的问题都会影响训练。

Evidence ID	证据问题	数据源	角色
OBS.VISUAL.AVAILABLE	三路 RGB 是否可用	video files, manifest	gate
OBS.VISUAL.L2_PASSES	人工视觉质检是否通过	L2 result	gate/score
OBS.MULTIVIEW.USABILITY	多视角是否共同覆盖关键区域	three RGB videos	review/planned
OBS.DEPTH.AVAILABLE	深度是否可用	depth files, manifest	optional/gate
OBS.OCCCLUSION.TARGET	目标或末端是否长期不可见	video/depth	review/research

OBS.ALIGNMENT.AC TION	观测与动作是否时间 对齐	timestamps, sync, video/action	gate/score
OBS.IMU.VIDEO.ST ABILITY	相机是否发生异常抖 动	IMU, video	diagnostic/score

11.2 L2 与 L3 的边界

L2 负责人工判断视觉质量，L3 v2 不应重复建设完整视觉质检系统。但 L3 应消费 L2 结果，并把它与动作证据、任务证据统一聚合。例如一条动作非常优秀但关键目标长期遮挡的数据，对视觉策略模型而言仍然训练价值有限。

12 Data Integrity and Synchronization 证据规范

12.1 设计目标

Data Integrity and Synchronization 证据回答：数据文件是否完整、时间轴是否可信、转换结果是否一致。该维度通常具有最高硬门控优先级，因为严重的数据完整性问题会直接破坏训练样本。

Evidence ID	证据问题	数据源	角色
DATA.FILE.COMPLE TE	必要 processed 文 件是否齐全	MinIO manifest/files	gate
DATA.TELEMETRY.S HEMA	telemetry 字段和 shape 是否符合预期	telemetry.npz	gate
DATA.TIME.REGULA RITY	timestamp 是否均 匀稳定	timestamps, manifest fps	gate/score
DATA.SYNC.VALIDA TION	跨传感器同步是否有 效	sync validation fields	gate/timeline
DATA.META.ALIGNM ENT	metadata 对齐配置 是否可信	metadata.json	gate/review
DATA.MANIFEST.CO NSISTENCY	manifest 与实际文 件是否一致	manifest, MinIO list	gate
DATA.CONVERSION. TRIM	裁剪区间是否合理	metadata trim ranges	review/score

DATA.VERSION.COM PATIBILITY	数据格式版本是否兼 容	manifest format version	gate
--------------------------------	----------------	----------------------------	------

12.2 同步异常证据

当前 L3 v1 已经使用 sync_validation_max_diff 生成同步异常 timeline。L3 v2 应保留该证据，但需要将其归入 Data Integrity，而不是 Motion Quality。同步异常影响的是 observation-state-action 配对可信度，因此它是训练数据硬门控或强负证据。

13 Dataset-Level Quality 证据规范

13.1 设计目标

Dataset-Level Quality 证据回答：一组 episode 是否适合构成训练集。单条 demonstration 的质量高，并不代表数据集质量高。模型训练还依赖覆盖、多样性、分布平衡和低冗余。该维度主要服务批次报告、数据集发布和主动采集改进。

Evidence ID	证据问题	数据源	角色
DSET.DIVERSITY.S CENE	场景和物体是否多样	metadata, video embedding	dataset/research
DSET.DIVERSITY.A CTION	动作分布是否多样	actions, qpos, EE pose	dataset/score
DSET.COVERAGE.TA SK	任务类型覆盖是否充 分	task metadata, prompt	dataset
DSET.BALANCE.SUC CESS	成功/失败或任务类别 是否失衡	L4, task labels	dataset
DSET.REDUNDANCY. NEAR_DUP	是否存在大量近重复 episode	trajectories, embeddings	dataset
DSET.OUTLIER.QUA LITY	是否存在异常离群样 本	all quality profiles	dataset/review
DSET.CALIBRATION .BASELINE	是否可建立同类任务 基线	approved samples	calibration

13.2 与 Episode 证据的区别

Episode evidence 主要判断单条数据是否可训练；Dataset evidence 判断数据集是否值得发布。一个数据集需要高质量 episode，也需要足够覆盖。未来批次报告应将这两类证据分开展示：先列出单条异常率，再列出分布覆盖和冗余问题。

14 Execution Diagnostics 证据规范

14.1 设计目标

Execution Diagnostics 证据回答：机器人执行侧是否存在控制、硬件或负载异常。它对排查采集质量和设备问题很有价值，但默认不直接决定训练数据价值，除非它已经导致任务失败、动作标签不可用或观测-动作关系严重扭曲。

Evidence ID	证据问题	数据源	角色
EXEC.TRACKING.COMMAND_ERROR	qpos 是否跟上 actions	actions, qpos	diagnostic
EXEC.TRACKING.LAG	是否存在明显控制延迟	actions, qpos, timestamps	diagnostic/review
EXEC.EFFORT.LOAD	effort 是否异常偏高	effort	diagnostic
EXEC.IMU.SHOCK	是否存在冲击或剧烈震动	IMU	diagnostic/timeline
EXEC.HARDWARE.STUCK	某些关节或手指疑似卡住	qpos, actions, effort	diagnostic/review
EXEC.CONTROLLER.OSCILLATION	控制执行是否震荡	actions, qpos, effort	diagnostic

14.2 Tracking Error 的重新定位

Command Tracking Error 衡量机器人实际状态 qpos 与遥操作目标 actions 的差异。它可以说明控制器响应、负载或硬件状态，但不等同于训练标签质量。对于模仿学习而言，actions 通常是监督标签，qpos 是 observation 中的状态。因此 Tracking Error 应作为诊断证据保留，但不应作为训练价值主评分项。

设计决策 EXEC-E1

Tracking Error 从 Core L3 Score 中降级为 Execution Diagnostics。只有当 tracking 异常导致任务失败、状态-动作配对不可解释或动作标签不可信时，才通过其他证据间接影响训练质量。

15 证据聚合原则

15.1 避免重复惩罚

同一个低质量现象可能被多个 metric 检测到。例如长时间无动作可能同时导致 Dead、Static、Low Dynamic Range、Low Information Density。证据层必须先合并语义，再聚合分数，避免重复惩罚。

设计决策 AGG-E1

聚合顺序必须是：metric result -> evidence state -> ontology dimension score -> overall quality。禁止直接把所有 metric score 加权平均成总分。

15.2 证据冲突处理

证据可能冲突。例如 L4 判定任务成功，但自动证据显示阶段缺失；动作饱和证据为负，但手部闭合阶段本来就需要饱和；tracking error 很高，但视频任务完成良好。系统应提供冲突标记，而不是强行平均。

冲突类型	示例	推荐处理
人工-自动冲突	L4 pass 但自动阶段证据缺失	标记为 review required，进入复核。
证据语义冲突	saturation 与 grasp phase 同时出现	降低 saturation 负权重，要求阶段解释。
诊断-训练冲突	tracking 差但 demonstration 好	保留诊断，不降低训练主分。
模态冲突	action 显示关键动作，但视频遮挡	标记 observation risk。
统计冲突	单条分数高但同类分布离群	进入 outlier review，不直接拒绝。

15.3 证据可信度

每个证据应输出 confidence。初期可以采用规则 confidence，例如数据字段存在性、窗口长度、同步状态、是否有人工结果；后期可以采用统计置信度或模型不确定性。低 confidence 的证据不应直接硬拒绝数据，而应触发人工复核或作为弱证据参与聚合。

16 Timeline Evidence 设计

16.1 Timeline 不只是异常段

L3 v1 的 timeline 主要输出异常段。L3 v2 的 timeline 应升级为 Evidence Timeline，包括四类片段。

片段类型	含义	示例
Anomaly Segment	明确负质量片段	同步异常、动作跳变、手指颤振。
Low-value Segment	学习信号较低但不一定错误	长时间无任务进展、重复等待。
Key-action Segment	对训练有价值的键动作片段	抓取、接触、放置、释放。
Review Segment	需要人工确认的片段	疑似失败、疑似抓错、阶段缺失。
Diagnostic Segment	设备或控制诊断片段	effort spike、IMU shock、tracking lag。

16.2 Timeline 输出规范

每个 timeline segment 推荐包含以下字段：

```
{
  "segment_id": "seg_0001",
  "start_sec": 3.20,
  "end_sec": 4.75,
  "evidence_id": "ACT.FINGER.CHATTER.v1",
  "ontology_path": ["Action Label Quality", "Finger Command Quality"],
  "segment_type": "anomaly",
  "severity": "warn",
  "confidence": 0.82,
  "human_label": "右手指令高频反向",
  "review_required": false,
  "linked_metrics": ["hand_chatter_rate"],
  "data_sources": ["actions", "timestamps"]
}
```


17 从 L3 v1 到 Evidence Layer 的迁移

17.1 现有指标迁移表

L3 v1 指标	新证据归属	迁移建议
LDLJ	BEH.SMOOTH.JOINT; ACT.SMOOTHNESS.ARM	保留为 joint/action 平滑性的候选 metric，后续扩展 EE Smoothness。
Dead Actions	LRN.IDENSITY.LOW_SIGNAL; ACT.RANGE.LOW	与 Static 合并为低信息证据，不再独立重复扣分。
Saturation	ACT.SATURATION.SEMANTIC	从硬惩罚改为语义证据，需结合任务阶段和持续时间。
Static	LRN.IDENSITY.LOW_SIGNAL; BEH.CONTINUITY.PAUSE	区分合理等待与无意义停顿。
Timestamp Jitter	DATA.TIME.REGULARITY	保留为数据完整性证据。
Tracking Error	EXEC.TRACKING.COMMAND_ERROR	降级为诊断证据，不作为训练主评分。
Hand Chatter	ACT.FINGER.CHATTER; BEH.DEXTERITY.COORDINATION	保留并优化 timeline 片段质量。
Effort	EXEC.EFFORT.LOAD	降级为诊断证据，结合任务和硬件状态解释。
Q_motion	Ontology dimension aggregation	废弃“单一 motion score”语义，替换为多维质量画像。

17.2 第一阶段可落地证据

基于当前数据，不依赖新增视觉模型，第一阶段建议落地以下证据：

- DATA.FILE.COMPLETE, DATA.TELEMETRY.SCHEMA, DATA.TIME.REGULARITY, DATA.SYNC.VALIDATION
- LRN.IDENSITY.LOW_SIGNAL, LRN.LABEL.DISCIMINABILITY
- ACT.VALIDITY.MISSING, ACT.RANGE.LOW, ACT.RANGE.OUTLIER, ACT.FINGER.CHATTER

- BEH.SMOOTH.JOINT, BEH.CONTINUITY.PAUSE, BEH.STABILITY.OSCILLATION
- STATE.JOINT.PLAUSIBILITY, STATE.JOINT.JUMP
- EXEC.TRACKING.COMMAND_ERROR, EXEC.EFFORT.LOAD

第二阶段再加入 EE pose 轨迹质量、trajectory efficiency、correction burden、task phase integrity；第三阶段加入视觉目标交互、VLM prompt alignment、dataset diversity embedding 等高级证据。

18 Evidence Registry 实现建议

18.1 Registry 数据结构

后端建议引入 Evidence Registry，使用 YAML/JSON 或数据库表定义证据元信息。示例：

```
evidence_id: LRN.IDENSITY.LOW_SIGNAL.v1
name_zh: 低学习信号片段
ontology_path:
  - Learnability
  - Information Density
question: 是否存在长时间缺乏有效动作和状态变化的片段
data_sources:
  - actions
  - qpos
  - timestamps
temporal_scope: segment
polarity: negative
role:
  - score
  - timeline
phase_sensitive: true
task_sensitive: true
human_review: optional
current_readiness: ready
candidate_metrics:
  - action_activity_ratio
  - state_activity_ratio
  - low_signal_duration_ratio
```

ui_group: Learnability
default_severity_policy: warn

18.2 数据库建议

未来可以建立四类表：

表	作用	关键字段
quality_dimension	保存本体节点	id、parent、name、version、scope。
evidence_registry	保存证据定义	evidence id、ontology path、data sources、role。
metric_registry	保存 metric 定义	metric id、evidence id、algorithm id。
episode_evidence	保存 episode 证据结果	episode id、evidence id、score、severity、confidence、segments。

19 前端 UI 对证据层的要求

19.1 质量维度优先

前端不应继续简单显示 LDLJ、Dead、Sat、Static 等算法卡片，而应按质量维度组织。例如：Learnability、Action Label Quality、Behavior Quality、Data Integrity、Execution Diagnostics。每个维度下显示证据摘要，再展开到具体 metric。

19.2 证据解释面板

推荐前端右侧质量面板显示：

- 维度分数：例如 Learnability 7.8。
- 证据摘要：例如 “存在 2 段低学习信号，共 3.4s”。
- 关键正证据：例如 “包含明显抓取与放置阶段”。
- 关键负证据：例如 “右手指令在 5.1s-6.0s 高频反向”。
- 诊断证据：例如 “command tracking 偏高，但未影响任务过程”。

19.3 Timeline 联动

点击 evidence segment 后，前端应同步跳转视频、曲线图和证据说明。曲线图上不再只标异常，而应显示证据类型：异常、低价值、关键动作、诊断、复核。

20 后续文档接口

20.1 Metric Mapping Specification

下一份建议文档是 Metric Mapping Specification。它应回答：每个 evidence 应由哪些 metrics 实现，每个 metric 依赖哪些字段，metric 的输出结构是什么。该文档仍不需要规定所有公式，但必须完成从 Evidence 到 Metric 的映射。

20.2 Algorithm Specification

Algorithm Specification 应在 Metric Mapping 之后编写。它才开始规定具体计算方法、窗口长度、滤波、归一化、阈值、timeline segment 合并规则和复杂度。

20.3 Implementation Specification

Implementation Specification 应描述后端类结构、API、缓存、异步任务、数据库表、版本控制和前端接口。此时才适合开始重构 l3_metrics.py。

21 结论

本文档将 RDDQF 从“质量本体”推进到“质量证据”。它确立了 L3 v2 的核心实现逻辑：不是直接计算一组孤立指标，而是为每个训练数据质量判断收集可解释证据。证据层使系统能够区分训练价值、动作标签质量、示范行为质量、数据完整性和执行诊断，避免把 Tracking Error、Effort、Saturation 等现象误解释为训练质量主判据。

完成证据层之后，L3 v2 的后续工作应进入 Metric Mapping：为每个证据选择候选指标，明确输入字段、输出结构和实现优先级。只有在证据和指标映射稳定之后，才应进入算法公式与代码实现阶段。

A 附录 A：推荐 Evidence Registry 总表

Evidence ID	中文名称	优先级	阶段
DATA.FILE.COMPLETE	必要文件完整性	P0	v2.0
DATA.TELEMETRY.SCHEMA	telemetry 结构有效性	P0	v2.0
DATA.TIME.REGULARITY	时间戳规则性	P0/P1	v2.0
DATA.SYNC.VALIDATION	跨传感器同步有效性	P0/P1	v2.0
ACT.VALIDITY.MISSING	动作标签缺失/异常	P0	v2.0
ACT.RANGE.OUTLIER	动作异常跳变	P1	v2.0
ACT.RANGE.LOW	动作变化过低	P1	v2.0
ACT.FINGER.CHATTER	手指命令高频反向	P1	v2.0
LRN.IDENSITY.LOW_SIGNAL	低学习信号片段	P1	v2.0
LRN.LABEL.DISCRIMINABILITY	标签可区分性	P1	v2.0
BEH.SMOOTH.JOINT	关节运动平滑性	P1	v2.0
BEH.CONTINUITY.PAUSE	不合理停顿	P1/P2	v2.0
BEH.STABILITY.OSCILLATION	运动震荡	P1/P2	v2.0
STATE.JOINT.PLAUSIBILITY	关节状态合理性	P1	v2.0
STATE.JOINT.JUMP	关节跳变	P1	v2.0
EXEC.TRACKING.COMMAND_ERROR	命令跟踪误差	P3	v2.0
EXEC.EFFORT.LOAD	effort 负载异常	P3	v2.0
BEH.SMOOTH.EE	末端轨迹平滑性	P1/P2	v2.1
STATE.EE.PATH_QUALITY	末端路径质量	P2	v2.1
BEH.EFFICIENCY.PATH	路径效率	P2	v2.1
BEH.CORRECTION.RETRY	纠错/重试负担	P2	v2.1
TASK.PHASE.INTEGRITY	任务阶段完整性	P1	v2.1

TASK.GOAL.COMPLETION	任务目标完成证据	P0/P1	v2.1
OBS.VISUAL.L2_PASS	L2 视觉质检结果	P0/P1	v2.1
OBS.ALIGNMENT.ACTION	观测-动作对齐	P0/P1	v2.1
DSET.COVERAGE.TASK	任务覆盖度	dataset	v2.2
DSET.REDUNDANCY.NEAR_DUP	近重复数据	dataset	v2.2
DSET.DIVERSITY.ACTION	动作多样性	dataset	v2.2

B 附录 B：证据到 UI 的默认显示策略

证据类型	UI 位置	交互方式
Hard Gate Evidence	顶部风险条和右侧质量摘要	显示为必须复核或不可训练。
Core Training Evidence	质量维度卡片	可展开查看 metric 和 timeline。
Timeline Evidence	播放进度条、曲线图背景、异常清单	点击跳转视频和曲线。
Diagnostic Evidence	折叠诊断面板	默认不影响主分，供排查使用。
Dataset Evidence	批次报告和数据集发布页	显示分布、覆盖、异常任务。

C 附录 C：术语表

术语	定义
Quality Ontology	训练数据质量的语义树，定义评价什么。
Evidence	支持质量判断的可观察事实或可计算信号。
Metric	用数值表达某个 evidence 的测量方式。
Algorithm	metric 的具体计算方法。

Evidence Registry	系统中所有 evidence 的结构化注册表。
Evidence Graph	evidence 与 quality dimension 的关系图。
Core Training Evidence	直接影响训练价值的证据。
Diagnostic Evidence	主要用于解释设备或执行异常的证据。
Timeline Evidence	可以定位到时间段的证据。
Low Learning Signal	对模型学习贡献较低的动作/状态/观测片段。

v1.1 实现同步附录：证据层解释性增强

实现阶段发现，仅给出 metric score 不足以指导人工复核。每条证据必须能够回答：哪个数据流、哪段时间、偏离多少、可能原因是什么、训练风险是什么。

Sensor-specific Evidence

DI-02 和 DI-03 必须输出 sensor-specific evidence。推荐字段包括：

- sourceSensor: 例如 wrist_left_camera, top_camera, qpos, actions;
- syncDiffMs: 当前帧或片段最大同步偏差;
- captureTimeSec: 相机真实采集时刻;
- episodeSec: 主时间轴时刻;
- durationSec: 异常持续时间;
- possibleCause: frame drop, stale frame reuse, stream freeze, sync algorithm error, video conversion issue;
- trainingRisk: observation-action temporal misalignment.

Camera Frame Index Sidecar

建议 processed 阶段新增 camera_frame_index.json，为前端和 L3 提供每帧相机真实采集时间：

```
cameraId, frameIndex, videoPtsSec, cameraCaptureSec, episodeSec, matchedTelemetrySec, syncDiffMs, isStale, isDuplicate, sourceFrameId
```

这样严重同步错位可以解释为：当前播放器时间虽然是 12.0s，但 wrist camera 的真实采集时间可能是 10.8s，因此该帧视觉 observation 已经落后主时间轴 1.2s。

Reliability Warning

若 DI-01、DI-02 或 DI-03 为 bad，或存在 sync_metadata_missing=true、hard sync violation、timestamp invalid，则必须输出 reliability warning：

检测到时间完整性问题，运动质量与学习价值相关指标的可信度可能下降。